



수집 데이터

1. 데이터 개요

구분	데이터명	데이터 수집 목적	데이터 형태	데이터 출처	데이터 크기	처리 상태	비고
DATA-001	한국소비자원 분쟁조정사례 데이터	KCA 분쟁조정사례 분석	pdf	한국소비자원	- 25.9mb - 22.5mb	- 파싱 완료 (upstage document parsing) - 전처리 완료 - 청킹 완료	
DATA-002	전자거래 분쟁조정사례집	전자거래 분쟁조정사례 분석	pdf	전자거래분쟁조정위원회	- 530mb	- 파싱 완료 (upstage document parsing) - 전처리 완료 - 청킹 완료	
DATA-003	콘텐츠분쟁조정 사례집	콘텐츠 분쟁조정 사례 분석	pdf	콘텐츠분쟁조정위원회	- 122mb	- 파싱 완료 (upstage document parsing) - 전처리 완료 - 청킹 완료	
DATA-004	소비자 상담 사례 데이터 (114)	소비자 상담 유형 분석 및 유사 사례 검색	웹 페이지 → JSONL	한국소비자원 1372 소비자상담	34.1MB (n ≈ 11342건)	수집 완료 전처리 완료 청킹 완료	상담 Q&A 중심
DATA-005	피해구제 사례 데이터 (115)	피해구제 기준 및 해결 사례 분석	웹 페이지 → JSONL	한국소비자원 소비자피해구제	6MB (n ≈ 1497건)	수집 완료 전처리완료 청킹 완료	보상·환급 사례 포함
DATA-006	분쟁조정 사례 데이터 (116)	분쟁조정 결과 및 조정 논리 분석	웹 페이지 → JSONL	한국소비자원 분쟁조정 사례	40.1MB (n ≈ 705건)	수집 완료 전처리 완료 청킹 완료	조정 결정문 기반
DATA-007	KCA 품목별 피해구제 사례 (0000006)	품목별 피해 유형 및 판단 기준 분석	웹 페이지 → JSONL	한국소비자원(KCA)	2.6MB (n ≈ 2466건)	수집 완료 전처리 완료 청킹 완료	품목 코드 기반
DATA-008	현행법령 본문	관련된 법조문 제공	XML → JSONL	https://open.law.go.kr/L_SQ/main.do	9.49MB (n≈11656건)	수집 완료 전처리 완료 청킹 완료	
DATA-009	현행법령 목록	법령명과 법령ID 매핑 정보 활용	XML → JSONL	https://open.law.go.kr/L_SQ/main.do	794KB (n≈5,534건)	수집 완료 전처리 완료	법령명, 법령약칭명, 법령ID, 법령 TYPE
DATA-010	소비자분쟁해결기준(공정거래위원회고시)(2025년)	분쟁 유형별 해결 기준 제공 및 근거 안내	PDF → JSONL	국가법령정보센터(소비자분쟁해결기준)	-393KB(별표 1) -3,247KB(별표 2) -191KB(별표 3) -62KB(별표 4)	수집 완료 전처리 완료	비정형 원문 구조화(JSONL)
DATA-011	전자상거래 등에서의 소비자보호지침(공정거래위원회고시)(2025년)	전자상거래 보호 원칙·의무 기준 안내	PDF → JSONL	국가법령정보센터(전자상거래 등에서의 소비자보호지침)	- 143KB	수집 완료 전처리 완료 청킹 완료	지침 원문 구조화(JSONL)
DATA-012	콘텐츠이용자 보호지침(문화체육관광부고시)(2024년)	콘텐츠 이용자 권리·분쟁 예방 기준 안내	PDF → JSONL	국가법령정보센터(콘텐츠이용자 보호지침)	- 355KB	수집 완료 전처리 완료 청킹 완료	지침 원문 구조화(JSONL)

2. 데이터 수집 및 활용의 적법성 검토

구분	상업 이용 가능	2차 가공 허용	학습 사용 허용	크롤링 이용약관 준수	개인정보 보호	비고
DATA-001	X	△	△	O	O	
DATA-002	X	△	△	O	O	
DATA-003	X	△	△	O	O	

구분	상업 이용 가능	2차 가공 허용	학습 사용 허용	크롤링 이용약관 준수	개인정보 보호	비고
DATA-004	X	△	△	O	O	비상업적·연구 목적 활용
DATA-005	X	△	△	O	O	공개 웹 정보 기반
DATA-006	X	△	△	O	O	판결·조정문 요약 목적
DATA-007	X	△	△	O	O	
DATA-008	O	O	O	O	O	
DATA-009	O	O	O	O	O	
DATA-010	O	O	O	O	O	공정거래위원회 고시, 법령성 문서
DATA-011	O	O	O	O	O	공정거래위원회 소비자보호 지침
DATA-012	O	O	O	O	O	문화체육관광부 고시, 공공 지침

3. 데이터 저장 및 관리

1. DATA-001 ~ DATA-003

- 저장 형식: JSONL
- 저장 환경: Vector DB

▼ 데이터 구조

```
{
  "source": "[출처 파일]",
  "agency": "[기관명]",
  "case_index": [사건 색인],
  "case_no": "[사건 번호]",
  "decision_date": "[결정 일자]",
  "chunk_type": "[청크 타입]",
  "text": "[청크 내용]",
  "case_uid": "[출처 파일]:1",
  "text_len": [길이],
  "drop": false,
  "seq": 1,
  "chunk_uid": "[청크 아이디]"
}
```

▼ 데이터 정제 및 전처리

- 중복 사건 제거
- 개행문자, 특수문자, 탭 제거
- Masking 일관화

2. DATA-004 ~ DATA-007 공통 구조

- 저장 형식: JSONL
- 저장 환경: 로컬 서버, DB 등

▼ 데이터 구조

```
{
  "doc_id": "consumer.go.kr:114:53321",
  "doc_type": "consumer_counsel_case",
  "title": "가전제품 정액감가상각 계산법 문의",
  "category_path": ["기계류기타물품", "기타미분류물품"],
  "source": "1372 소비자 상담센터",
  "url": "https://consumer.go.kr/...",
  "collected_at": "2025-12-27T17:44:51Z",
  "text": "[질문] ... [답변] ..."
}
```

▼ 데이터 정제 및 전처리

- HTML 태그 제거 (BeautifulSoup 기반)
- 불필요한 공백, 특수문자 정리
- 질문/답변 구조 유지
- 중복 문서 제거 (doc_id 기준)
- 날짜, 출처, 분류 메타데이터 정규화

3. DATA-008

- 저장 형식: JSONL
- 저장 환경: 로컬 서버

▼ 데이터 구조

```
{
  "law_id": "001706",      # 법령ID
  "law_name": "민법",      # 법령명
  "law_type": "법률",      # 법령TYPE
  ...
}
```

```

"doc_id": "001706|A1", # APIM 코드로 doc_id 생성
"parent_id": null, # 조항호목 계층적 구조이므로 parent의 doc_id 저장
"is_indexable": false, # 유사도 검색에 사용할 구문인지에 대한 정보

"article_title": "", # 조문 이름
"text": "제1편 총칙 제1장 통칙", # 조문 내용

"ref_citations_internal": [], # 준용문(이 법)
"ref_citations_external": [], # 준용문(다른 법)
"mentioned_laws": [] # 언급된 법
}

```

▼ 데이터 정제 및 전처리

1. 여러 공백이나 ` ` 제거

```

<조문내용>
  <![CDATA[          제2장 상인]]>
</조문내용>

```

2. 특수기호 숫자를 숫자로 매핑. ① → 1
단, <항내용>의 ①은 제거 x (항, 호, 목이 각자 다른 형태의 일련번호를 가지므로 의미가 있다고 판단)

```

<항>
  <항번호><![CDATA[①]]></항번호>
  <항내용><![CDATA[① 법정대리인이 미성년자, 피한정후견인 또는 피성년후견인을 위하여 영업을 하는 때에는 등기를 하여야 한다. <개정 2
018.9.18>]]>
  </항내용>
</항>

```

3. 본문 마지막에 달린 개정 꼬리표 (<개정 ...>) 분리
4. 조항호목 체계지만 중간에 항이나 호 없이 바로 조-호나 조-목으로 가는 법령 조문도 누락없이 저장
예시:

```

# 호 없이 조-항-목인 경우

if is_shell_px: # 항도 존재하지 않을 때
    sub_id = f"{article_id}|M{sub_no}"
    para_no_for_path = None
else: # 항이 존재할 때
    sub_id = f"{article_id}|P{para_no or 'X'}|M{sub_no}"
    para_no_for_path = para_no

```

5. 내부 법령 준용, 외부 법령 준용문구 추출
파서 일부:

```

ARTICLE_RANGE_RE = re.compile(
    r"제(?:P<s>\d+)?(?:의(?:P<sd>\d+))?\s*(?:부터|내지)\s*제(?:P<e>\d+)?(?:의(?:P<ed>\d+))?\s*(?:까지)?"
)
PARA_RANGE_ONLY_RE = re.compile(r"제(?:P<s>\d+)?항\s*부터\s*제(?:P<e>\d+)?항\s*까지")
ITEM_RANGE_ONLY_RE = re.compile(r"제(?:P<s>\d+)?호\s*부터\s*제(?:P<e>\d+)?호\s*까지")

```

4. DATA-009

- 저장 형식: JSONL
- 저장 환경: 로컬 서버

▼ 데이터 구조

```

{
  "law_name": "전자상거래 등에서의 소비자보호에 관한 법률",
  "law_short_name": "전자상거래법",
  "law_id": "009318",
  "law_type": "법률"
}

```

▼ 데이터 정제 및 전처리

API로 얻은 XML 원본

```

<law id="2901">
  <법령일련번호>277187</법령일련번호>
  <현행연혁코드>현행</현행연혁코드>
  <법령명한글> <![CDATA[ 소나무재선충병 방제특별법 ]]> </법령명한글>
  <법령약칭명> <![CDATA[ 재선충방제법 ]]> </법령약칭명>
  <법령ID>009940</법령ID>
  <공포일자>20251001</공포일자>
  <공포번호>21065</공포번호>
  <제개정구분명>타법개정</제개정구분명>
  <소관부처코드>1400000</소관부처코드>
  <소관부처명>산림청</소관부처명>
  <법령구분명>법률</법령구분명>
  <공동부령정보/>
  <시행일자>20251001</시행일자>
  <자법타법여부/>
</law>

```

<법령명한글> , <법령약칭명> , <법령ID> , <법령구분명> 만 `xml.etree.ElementTree` 로 파싱해 json으로 저장.

5. DATA-010 ~ DATA-012 공통 구조

- 저장 형식: JSONL
- 저장 환경: 로컬 서버

▼ 데이터 구조

```

json
{
  "law_id": "001706",
  "law_name": "소비자분쟁해결기준",
  "law_type": "고시",
  "doc_id": "001706|A1",
  "parent_id": null,
  "article_title": "총칙",
  "text": "이 기준은 소비자 분쟁 발생 시 해결을 위한 기준을 정한다.",
  "is_indexable": true,
  "ref_citations_internal": [],
  "ref_citations_external": [],
  "mentioned_laws": []
}

```

- 법령·고시·지침 문서는 **조문 단위로 분리**하여 관리
- `doc_id` 를 기준으로 조·항·호·목의 **계층 구조 유지**
- 검색 및 활용 목적에 따라 `is_indexable` 플래그로 색인 대상 여부 구분

▼ 데이터 정제 및 전처리

- PDF 원문을 JSONL 형태로 변환하여 저장
- 불필요한 개행, 공백, 특수문자 정리
- 조문 말미의 개정 이력 및 부가 설명 분리
- 항·호·목 번호 기호(①, ② 등) 숫자 표기로 정규화
- 내부 준용(동일 법령), 외부 준용(타 법령) 문구 분리 추출
- 법령명, 법령ID, 법령 유형 메타데이터 정규화