



인공지능 데이터 전처리 결과서

1. 데이터 개요

1.1. 전처리 목적

1.2. 문제 정의

구분	데이터명	데이터 수집 목적	데이터 형태	데이터 출처	데이터 크기	처리 상태	비고
DATA-001	한국소비자원 분쟁조정사례 데이터	KCA 분쟁조정사례 분석	pdf	한국소비자원	- 25.9mb - 22.5mb	- 파싱 완료 (upstage document parsing) - 전처리 완료 - 청킹 완료	
DATA-002	전자거래 분쟁조정사례집	전자거래 분쟁조정사례 분석	pdf	전자거래분쟁조정위원회	- 530mb	- 파싱 완료 (upstage document parsing) - 전처리 완료 - 청킹 완료	
DATA-003	콘텐츠분쟁조정 사례집	콘텐츠 분쟁조정 사례 분석	pdf	콘텐츠분쟁조정위원회	- 122mb	- 파싱 완료 (upstage document parsing) - 전처리 완료 - 청킹 완료	
DATA-004	소비자 상담 사례 데이터 (114)	소비자 상담 유형 분석 및 유사 사례 검색	웹 페이지 → JSONL	한국소비자원 1372 소비자상담	34.1MB (n ≈ 11342건)	수집 완료 전처리 완료 청킹 완료	상담 Q&A 중심
DATA-005	피해구제 사례 데이터 (115)	피해구제 기준 및 해결 사례 분석	웹 페이지 → JSONL	한국소비자원 소비자피해구제	6MB (n ≈ 1497건)	수집 완료 전처리완료 청킹 완료	보상·환급 사례 포함
DATA-006	분쟁조정 사례 데이터 (116)	분쟁조정 결과 및 조정 논리 분석	웹 페이지 → JSONL	한국소비자원 분쟁조정 사례	40.1MB (n ≈ 705건)	수집 완료 전처리 완료 청킹 완료	조정 결정문 기반
DATA-007	KCA 품목별 피해구제 사례 (0000006)	품목별 피해 유형 및 판단 기준 분석	웹 페이지 → JSONL	한국소비자원(KCA)	2.6MB (n ≈ 2466건)	수집 완료 전처리 완료 청킹 완료	품목 코드 기반
DATA-008	현행법령 본문	관련된 법조문 제공	XML → JSONL	https://open.law.go.kr/L_SO/main.do	9.49MB (n≈11656건)	수집 완료 전처리 완료 청킹 완료	
DATA-009	현행법령 목록	법령명과 법령ID 매핑 정보 활용	XML → JSONL	https://open.law.go.kr/L_SO/main.do	794KB (n≈5534건)	수집 완료 전처리 완료	법령명, 법령약칭명, 법령ID, 법령 TYPE
DATA-010	소비자분쟁해결기준(공정거래위원회고시)(2025년)	분쟁 유형별 해결 기준 제공 및 근거 안내	PDF → JSONL	국가법령정보센터(소비자분쟁해결기준)	- 393KB(별표 1) - 3,247KB(별표 2) - 191KB(별표 3) - 62KB(별표 4)	수집 완료 전처리 완료	비정형 원문 구조화(JSONL)
DATA-011	전자상거래 등에서의 소비자보호지침(공정거래위원회고시)(2025년)	전자상거래 보호 원칙·의무 기준 안내	PDF → JSONL	국가법령정보센터(전자상거래 등에서의 소비자보호지침)	- 143KB	수집 완료 전처리 완료 청킹 완료	지침 원문 구조화(JSONL)
DATA-012	콘텐츠이용자 보호지침(문화체육관광부고시)(2024년)	콘텐츠 이용자 권리·분쟁 예방 기준 안내	PDF → JSONL	국가법령정보센터(콘텐츠이용자 보호지침)	- 355KB	수집 완료 전처리 완료 청킹 완료	지침 원문 구조화(JSONL)

- 데이터 수집 기간: 2025.12.18. - 2025.12.29.
- 전체 수집 데이터 건수:
 - 법령 데이터

- 문서 20개 / 청크 6300개
- 피해구제사례데이터
 - 문서 13544개 / 청크 13544개
- 분쟁조정사례데이터
 - 문서 3173개 / 청크 11755개
- 분쟁조정기준 데이터
 - 문서 6개 / 청크 892개

2. 데이터 수집 및 활용의 적법성 검토

구분	상업 이용 가능	2차 가공 허용	학습 사용 허용	크롤링 이용약관 준수	개인정보 보호	비고
DATA-001	X	△	△	O	O	
DATA-002	X	△	△	O	O	
DATA-003	X	△	△	O	O	
DATA-004	X	△	△	O	O	비상업적·연구 목적 활용
DATA-005	X	△	△	O	O	공개 웹 정보 기반
DATA-006	X	△	△	O	O	판결·조정문 요약 목적
DATA-007	X	△	△	O	O	
DATA-008	O	O	O	O	O	
DATA-009	O	O	O	O	O	
DATA-010	O	O	O	O	O	공정거래위원회 고시, 법령성 문서
DATA-011	O	O	O	O	O	공정거래위원회 소비자보호 지침
DATA-012	O	O	O	O	O	문화체육관광부 고시, 공공 지침

- 저작권 준수: 해당 데이터의 이용약관을 검토하여 상업적 이용 및 2차 가공 가능 여부를 확인하였습니다.
- 크롤링 이용약관 준수: Robots.txt 규정에 따라 서버에 부하를 주지 않는 방식으로 크롤링을 수행하였습니다.
- 개인정보 보호: 수집 과정에서 개인 식별 정보(이름, 연락처 등)는 즉시 제외하거나 비식별 처리를 완료하였습니다.
 - 수집된 데이터 중 “사례집” 데이터는 각 조정위원회에서 마스킹 처리 완료

3. 데이터 수집 방법

[참고] 수집 방법이 동일한 데이터는 하나의 방식으로 통합하여 기재해주세요.

1. DATA-001 ~ DATA-003

- 수집 방식 및 도구
 - PDF 파싱 (Upstage Document Parsing) → response.json → merged_text_elements.txt
 - JSON, JSONL 변환 (merged_text_elements.txt → [기관명]_final.json, [기관명]_final.jsonl)
 - 청킹 및 임베딩
 - 문서 기반 청킹
- ▮ 헤더 같은 구조적 요소를 기준으로만 분할합니다. 뉴스 기사, 고객 지원 티켓, 마크다운 파일처럼 독립적인 짧은 문서들이나 구조화된 파일에 효과적입니다

2. DATA-004 ~ DATA-007

- 수집 방식 및 도구
 - **수집원**: 소비자원/소비자포털 웹 공개 데이터
 - 웹 페이지(HTML) 기반 공개 사례 데이터를 **크롤링**(HTTP 요청/브라우저 자동화)하여 원문을 수집
 - 페이지 HTML에서 **제목/분류/본문(질문·답변/판단·결론)** 텍스트를 파싱하여 정제
 - 문서 단위로 `doc_id`, `doc_type`, `category_path`, `text_for_embedding`, `url` 을 포함한 **JSONL로 정규화 후 청킹**

3. DATA-008

- 수집 방식 및 도구
 - API requests → 법령.xml 원본
 - JSONL 변환
 - 청킹 및 임베딩

- 조항호목 계층적 구조로 인한 조 단위 혹은 항 단위 묶음 처리
- 청크 저장된 [법령명]_chunks.jsonl 파일 생성

4. DATA-009

- 수집 방식 및 도구
 - API requests → 필요 태그 파싱, JSONL 변환
 - 청킹 및 임베딩 대상 X

5. DATA-010 ~ DATA-012

- 수집 방식 및 도구
 - 국가법령정보센터 제공 파일 직접 다운로드
 - 법령·고사·지침 PDF 원문 수집
 - PDF → JSONL 변환
 - PDF 원문 파싱 후 텍스트 추출
 - 조문 단위로 분리하여 JSON / JSONL 형태로 저장
 - 전처리 및 청킹
 - 불필요한 공백·개행·특수문자 제거
 - 조·항·호·목 구조 유지
 - 활용 목적에 따라 조문 단위로 청킹

4. 데이터 저장 및 관리

1. DATA-001 ~ DATA-003

- 저장 형식: JSONL
- 저장 환경: Vector DB

▼ 데이터 구조

```
{"source": "[출처 파일]", "agency": "[기관명]", "case_index": "[사건 색인]", "case_no": "[사건 번호]", "decision_date": "[결정 일자]", "chunk_type": "[청크 타입]", "text": "[청크 내용]", "case_uid": "[출처 파일]:1", "text_len": [길이], "drop": false, "seq": 1, "chunk_uid": "[청크 아이디]}
```

▼ 데이터 정제 및 전처리

- 중복 사건 제거
- 개행문자, 특수문자, 탭 제거
- Masking 일관화

2. DATA-004 ~ DATA-007 공통 구조

- 저장 형식: JSONL
- 저장 환경: Vector DB

▼ 데이터 구조

```
{
  "doc_id": "consumer.go.kr:114:53321",
  "doc_type": "consumer_counsel_case",
  "title": "가전제품 정액감가상각 계산법 문의",
  "category_path": ["기계류기타물품", "기타미분류물품"],
  "source": "1372 소비자 상담센터",
  "url": "https://consumer.go.kr/...",
  "collected_at": "2025-12-27T17:44:51Z",
  "text": "[질문] ... [답변] ..."
}
```

▼ 데이터 정제 및 전처리

- HTML 태그 제거 (BeautifulSoup 기반)
- 불필요한 공백, 특수문자 정리
- 질문/답변 구조 유지
- 중복 문서 제거 (doc_id 기준)
- 날짜, 출처, 분류 메타데이터 정규화

3. DATA-008

- 저장 형식: JSONL
- 저장 환경: RDB, Vector DB

▼ 데이터 구조

```
{
  "law_id": "001706",      # 법령ID
  "law_name": "민법",      # 법령명
  "law_type": "법률",      # 법령TYPE

  ...

  "doc_id": "001706|A1",   # APIM 코드로 doc_id 생성
  "parent_id": null,       # 조항호목 계층적 구조이므로 parent의 doc_id 저장
  "is_indexable": false,   # 유사도 검색에 사용할 구문인지에 대한 정보

  "article_title": "",     # 조문 이름
  "text": "제1편 총칙 제1장 통칙", # 조문 내용

  "ref_citations_internal": [], # 준용문(이 법)
  "ref_citations_external": [], # 준용문(다른 법)
  "mentioned_laws": []      # 언급된 법
}
```

▼ 데이터 정제 및 전처리

- 여러 공백이나 ` ` 제거

```
<조문내용>
  <![CDATA[          제2장 상인]]>
</조문내용>
```

- 특수기호 숫자를 숫자로 매핑. ① → 1
단, <항내용>의 ①은 제거 x (항, 호, 목이 각자 다른 형태의 일련번호를 가지므로 의미가 있다고 판단)

```
<항>
  <항번호><![CDATA[①]]></항번호>
  <항내용><![CDATA[① 법정대리인이 미성년자, 피한정후견인 또는 피성년후견인을 위하여 영업을 하는 때에는 등기를 하여야 한다. <개정 2
018.9.18>]]>
  </항내용>
</항>
```

- 본문 마지막에 달린 개정 꼬리표(<개정 ...>) 분리
- 조항호목 체계지만 중간에 항이나 호 없이 바로 조-호나 조-목으로 가는 법령 조문도 누락없이 저장
예시:

```
# 호 없이 조-항-목인 경우

if is_shell_px:          # 항도 존재하지 않을 때
  sub_id = f"{article_id}|M{sub_no}"
  para_no_for_path = None
else:                    # 항이 존재할 때
  sub_id = f"{article_id}|P{para_no or 'X'}|M{sub_no}"
  para_no_for_path = para_no
```

- 내부 법령 준용, 외부 법령 준용문구 추출

파서 일부:

```
ARTICLE_RANGE_RE = re.compile(
  r"제(?:P<s>\d+)?(?:\d+)?\s*(?:부터|내지)\s*제(?:P<e>\d+)?(?:\d+)?\s*(?:까지)?"
)
PARAMETER_RANGE_ONLY_RE = re.compile(r"제(?:P<s>\d+)?\s*부터\s*제(?:P<e>\d+)?\s*까지")
ITEM_RANGE_ONLY_RE = re.compile(r"제(?:P<s>\d+)?\s*부터\s*제(?:P<e>\d+)?\s*까지")
```

4. DATA-009

- 저장 형식: JSONL
- 저장 환경: 로컬 서버

▼ 데이터 구조

```
{
  "law_name": "전자상거래 등에서의 소비자보호에 관한 법률",
  "law_short_name": "전자상거래법",
  "law_id": "009318",
  "law_type": "법률"
}
```

▼ 데이터 정제 및 전처리

API로 얻은 XML 원본

```
<law id="2901">
  <법령일련번호>277187</법령일련번호>
  <현행연혁코드>현행</현행연혁코드>
  <법령명한글> <![CDATA[ 소나무재선충병 방제특별법 ]]> </법령명한글>
  <법령약칭명> <![CDATA[ 재선충방제법 ]]> </법령약칭명>
  <법령ID>009940</법령ID>
  <공포일자>20251001</공포일자>
  <공포번호>21065</공포번호>
  <제개정구분명>타법개정</제개정구분명>
  <소관부처코드>1400000</소관부처코드>
  <소관부처명>산림청</소관부처명>
  <법령구분명>법률</법령구분명>
  <공동부령정보/>
  <시행일자>20251001</시행일자>
  <자법타법여부/>
</law>
```

<법령명한글>, <법령약칭명>, <법령ID>, <법령구분명> 만 `xml.etree.ElementTree` 로 파싱해 jsonl로 저장.

5. DATA-010 ~ DATA-012 공통 구조

- 저장 형식: JSONL
- 저장 환경: 로컬 서버

▼ 데이터 구조

```
json

{
  "law_id": "001706",
  "law_name": "소비자분쟁해결기준",
  "law_type": "고시",
  "doc_id": "001706|A1",
  "parent_id": null,
  "article_title": "총칙",
  "text": "이 기준은 소비자 분쟁 발생 시 해결을 위한 기준을 정한다.",
  "is_indexable": true,
  "ref_citations_internal": [],
  "ref_citations_external": [],
  "mentioned_laws": []
}
```

- 법령·고시·지침 문서는 **조문 단위로 분리**하여 관리
- `doc_id` 를 기준으로 조·항·호·목의 **계층 구조 유지**
- 검색 및 활용 목적에 따라 `is_indexable` 플래그로 색인 대상 여부 구분

▼ 데이터 정제 및 전처리

- PDF 원문을 JSONL 형태로 변환하여 저장
- 불필요한 개행, 공백, 특수문자 정리
- 조문 말미의 개정 이력 및 부가 설명 분리
- 항·호·목 번호 기호(①, ② 등) 숫자 표기로 정규화
- 내부 준용(동일 법령), 외부 준용(타 법령) 문구 분리 추출
- 법령명, 법령ID, 법령 유형 메타데이터 정규화

5. 데이터 전처리

5.1. 이상치 탐지 및 처리

- 이상치 기준: X
- 처리 방법: X
- 처리 결과: "법령", "사례집", "조정 기준" 데이터 특성 상, 이상치가 존재하지 않음

5.2. 결측치 처리

- 대상 결측 필드: “사건 번호”
- 결측치 발생 건수(비율): 1건 (KCA)
- 처리 방법: 중복 사건 삭제
- 처리 결과: 중복 사건 삭제

5.2. 데이터 정제

[참고] 정규화/표준화를 위한 추가 전처리 내역 작성

(1) 필드명 표준화 적용

- 기준
- 처리 과정
- 적용 내용: 서로 다른 표기 형태의 필드명을 통합하여 관리
- 활용 방안: 표준화된 필드명을 RAG 인덱싱 및 파인튜닝 학습 데이터셋 구성에 활용하여, 데이터 처리 자동화와 검색 품질의 일관성을 확보

(2) 특수문자 처리

- 개행 문자(**\n**) 정리 및 중복 공백 제거
- 특수문자 표기 통일
 - , , ,  등 문서마다 혼재된 기호를 의미 유지 범위 내에서 정규화
- 익명화/마스킹 정보 표기 통일
 - **[익명]**, **000**, ****** 등의 표현을 **[MASKED]** 형식으로 통일
- 처리 과정: 정규식 기반으로 특수문자를 탐지한 후 제거
- 적용 내용

```
def preprocess_for_rag(text: str) -> str:
    """
    RAG 시스템에 최적화된 텍스트 전처리

    - 페이지 마커 제거
    - 페이지 번호/헤더 제거
    - 문장 중간 개행 병합 (OCR 오류 수정)
    - 과도한 공백 정리
    - 특수문자 일부 정규화

    """

    # 1. 페이지 마커 제거
    text = re.sub(r'\n*== PAGE \d+ ==\n*', '\n', text)

    # 2. 페이지 번호/헤더/푸터 제거
    text = re.sub(r'\d+\s+\d{4}\s+의료분쟁조정\s+사례집', '', text)
    text = re.sub(r'제\d+장\s+본쟁조정\s+주요\s+사례\s+\d+', '', text)
    text = re.sub(r'내과분야\s*\n* | \^*\n*', '', text)

    # 3. 문장 중간 개행 병합 (OCR 오류: "유\n방" -> "유방")
    # 한글-개행-한글(1~2자)-공백 패턴
    text = re.sub(r'([가-힣])\n([가-힣]{1,2})\s', r'\1\2 ', text)

    # 4. 특수 구두점 정규화 (의미 유지)
    text = text.replace('*', '[주]') # 주석 표시
    text = text.replace(' | ', '|') # 구분자

    # 5. 과도한 개행 정리 (3개 이상 -> 2개)
    text = re.sub(r'\n{3,}', '\n\n', text)

    # 6. 다중 공백 제거 (2개 이상 -> 1개)
```

```

text = re.sub(r' {2,}', ' ', text)

# 7. 각 줄의 앞뒤 공백 제거
lines = [line.strip() for line in text.split('\n')]
text = '\n'.join(line for line in lines if line)

# 8. 전체 앞뒤 공백 제거
text = text.strip()

return text

```

- 활용 방안:
 - 임베딩 벡터가 **불필요한 노이즈 없이 의미 중심으로 생성**
 - 데이터전처리에 대해서 안정적인 검색 결과 확보
 - 향후 LLM 응답 생성 시 불필요한 특수문자 출력 감소

6. 전처리 프로세스 개요

- 전체 흐름도:
- ① 수집 → ② 결측치 탐지 → ③ 정규화 → ④ 데이터 청킹 → ⑤ 데이터 임베딩

- 전처리 파이프라인 요약:

단계	목적	수행 작업	사용 도구/라이브러리
수집	데이터 수집	pdf parsing, crawling	Upstage Document parsing, BeautifulSoup4 xml.etree.ElementTree
결측치 탐지	결측치 제거	중복값 제거	
정규화	특수문자 처리	개행문자, 탭문자 등 parsing 결과 전처리	regex
데이터 청킹	RAG 활용	문서 기반 청킹	
데이터 임베딩	유사도 기반 검색	RunPod 활용 문서 임베딩	KURE-v1, text-embedding-3-small