



수집된 데이터 및 데이터 전처리 문서

1. 데이터 설명 및 구성

1.1. 데이터 및 필드 설명

documents

```
CREATE TABLE documents (  
  doc_id VARCHAR(255) PRIMARY KEY,      -- 문서 고유 ID  
  doc_type VARCHAR(50) NOT NULL,        -- 타입 구분: 'law', 'mediation_case', 'counsel_  
case', 'criteria_*'  
  title TEXT NOT NULL,                  -- 문서 제목  
  source_org VARCHAR(100),              -- 출처 기관: 'KCA', 'ECMC', 'statute' 등  
  category_path TEXT[],                 -- 카테고리 경로: {'농수축산물', '란류'}  
  url TEXT,                             -- 원본 URL  
  collected_at TIMESTAMP,               -- 수집 일시  
  metadata JSONB,                      -- 유연한 메타데이터 (referenced_laws, case_number 등)  
  created_at TIMESTAMP DEFAULT NOW(),  
  updated_at TIMESTAMP DEFAULT NOW()  
);
```

```
-- 예시 1: 법령 문서  
INSERT INTO documents VALUES (  
  '001589',                          -- doc_id  
  'law',                             -- doc_type  
  '소비자기본법',                    -- title  
  'statute',                         -- source_org  
  ARRAY['소비자', '기본법'],          -- category_path  
  'https://www.law.go.kr/법령/소비자기본법', -- url  
  '2026-01-01 00:00:00',              -- collected_at  
  '{"law_number": "제19357호", "enforcement_date": "2024-01-01"}':jsonb, -- metadata  
  NOW(),  
  NOW()  
);
```

```
-- 예시 2: 분쟁조정사례 문서  
INSERT INTO documents VALUES (  
  'kca_2015_case_27',                -- doc_id  
  'mediation_case',                  -- doc_type
```

```

'온라인 신선식품 부패 환불 요구',      -- title
'KCA',                                    -- source_org
ARRAY['상품(재화)', '농수축산물', '란류'], -- category_path
'https://www.kca.go.kr/case/2015/27',    -- url
'2025-12-01 10:30:00',                  -- collected_at
'{"case_number": "2015일가27", "decision_date": "2015-03-15", "referenced_laws": ["001
589|A10", "000422|A23"]}'::jsonb,
NOW(),
NOW()
);

-- 예시 3: 소비자분쟁해결기준 문서
INSERT INTO documents VALUES (
'table2_agricultural',      -- doc_id
'criteria_resolution',      -- doc_type
'농수축산물 분쟁해결기준', -- title
'KCA',                      -- source_org
ARRAY['상품(재화)', '농수축산물'], -- category_path
'https://www.kca.go.kr/criteria/table2', -- url
'2026-01-01 00:00:00',      -- collected_at
'{"table_name": "table2", "part": "농수축산물"}'::jsonb,
NOW(),
NOW()
);

```

chunks

```

CREATE TABLE chunks (
  chunk_id VARCHAR(255) PRIMARY KEY,      -- 청크 고유 ID
  doc_id VARCHAR(255) NOT NULL            -- 외래키: 어떤 문서에 속하는지
    REFERENCES documents(doc_id) ON DELETE CASCADE,
  chunk_index INTEGER NOT NULL,           -- 청크 순서 (0-based)
  chunk_total INTEGER NOT NULL,           -- 해당 문서의 총 청크 수
  chunk_type VARCHAR(50),                 -- 청크 타입: 'article', 'resolution_row', 'decision' 등
  content TEXT NOT NULL,                  -- 청크 내용 (실제 텍스트)
  content_length INTEGER,                 -- 내용 길이
  embedding_vector(1024),                 -- 벡터 임베딩 (KURE-v1, 1024차원)
  embedding_model VARCHAR(50) DEFAULT 'KURE-v1',
  drop BOOLEAN DEFAULT FALSE,             -- 삭제 플래그 (검색 제외)
  created_at TIMESTAMP DEFAULT NOW(),
  updated_at TIMESTAMP DEFAULT NOW(),
  UNIQUE(doc_id, chunk_index),            -- 동일 문서 내 중복 인덱스 방지
  CHECK (chunk_index >= 0),               -- 0-based indexing
  CHECK (chunk_total > 0),

```

```
CHECK (chunk_index < chunk_total)
);
```

-- 예시 1: 법령 조문 청크

```
INSERT INTO chunks VALUES (
  '001589_A10_P1',          -- chunk_id
  '001589',                 -- doc_id (소비자기본법)
  9,                        -- chunk_index (10번째 청크)
  50,                       -- chunk_total (총 50개 청크)
  'paragraph',             -- chunk_type (항)
  '제10조(소비자의 기본적 권리) ① 소비자는 물품 또는 용역(이하 "물품등"이라 한다)을 사용함에 있어
서 생명·신체 또는 재산에 대한 위해로부터 보호받을 권리를 가진다.',
  120,                      -- content_length
  '[0.123, -0.456, 0.789, ...]::vector(1024), -- embedding (실제로는 1024차원)
  'KURE-v1',
  FALSE,
  NOW(),
  NOW()
);
```

-- 예시 2: 분쟁조정사례 결정문 청크

```
INSERT INTO chunks VALUES (
  'kca_2015_case_27_decision', -- chunk_id
  'kca_2015_case_27',         -- doc_id (분쟁조정사례)
  2,                           -- chunk_index (3번째 청크)
  5,                           -- chunk_total (총 5개 청크)
  'decision',                 -- chunk_type (결정문)
  ' 【결정】 신청인이 구입한 란류(계란)가 부패하여 반품을 요구하였으나 피신청인이 거부한 사안에서,
소비자분쟁해결기준에 따라 구입가 환급을 명함. 근거: 종자산업법 제23조, 소비자기본법 제10조.',
  150,                         -- content_length
  '[0.234, -0.567, 0.890, ...]::vector(1024),
  'KURE-v1',
  FALSE,
  NOW(),
  NOW()
);
```

-- 예시 3: 소비자분쟁해결기준 청크

```
INSERT INTO chunks VALUES (
  'table2_row_egg_spoilage', -- chunk_id
  'table2_agricultural',      -- doc_id (농수축산물 기준)
  0,                          -- chunk_index (첫 번째 청크)
  1,                          -- chunk_total (총 1개 청크)
  'resolution_row',          -- chunk_type (해결기준 행)
  ' 【품목】 1란류, 2육류, 3곡류, 4과일, 5야채류, 6수산물류\n 【분쟁유형】 부패, 변질\n 【해결기준】
o 당해품목 교환 또는 구입가 환급\n 【관련법령】 종자산업법 제23조',
```

```

200,                                -- content_length
'[0.345, -0.678, 0.901, ...]':vector(1024),
'KURE-v1',
FALSE,
NOW(),
NOW()
);

```

chunk_relations

```

CREATE TABLE chunk_relations (
  source_chunk_id VARCHAR(255) NOT NULL    -- 관계의 출발 청크
    REFERENCES chunks(chunk_id) ON DELETE CASCADE,
  target_chunk_id VARCHAR(255) NOT NULL    -- 관계의 도착 청크
    REFERENCES chunks(chunk_id) ON DELETE CASCADE,
  relation_type VARCHAR(50) NOT NULL,      -- 관계 타입:
    -- 'next': 다음 청크 (순차)
    -- 'prev': 이전 청크 (역순)
    -- 'cited': 인용 관계 (A가 B를 인용)
    -- 'related': 연관 관계 (유사 주제)
  created_at TIMESTAMP DEFAULT NOW(),
  PRIMARY KEY (source_chunk_id, target_chunk_id, relation_type),
  CHECK (confidence >= 0.0 AND confidence <= 1.0)
);

```

-- 예시 1: 법령 조문 순차 관계

```

INSERT INTO chunk_relations VALUES (
  '001589_A10_P1',                -- source (제10조 제1항)
  '001589_A10_P2',                -- target (제10조 제2항)
  'next',                          -- relation_type (다음 항)
  NOW()
);

```

-- 예시 2: 분쟁조정사례가 법령을 인용

```

INSERT INTO chunk_relations VALUES (
  'kca_2015_case_27_decision',     -- source (사례 결정문)
  '001589_A10_P1',                -- target (소비자기본법 제10조 제1항)
  'cited',                         -- relation_type (인용)
  NOW()
);

```

```

INSERT INTO chunk_relations VALUES (
  'kca_2015_case_27_decision',     -- source (사례 결정문)
  'table2_row_egg_spoilage',      -- target (분쟁해결기준)

```

```

'cited',                                -- relation_type (기준 적용)
NOW()
);

-- 예시 3: 유사한 사례 간 연관 관계
INSERT INTO chunk_relations VALUES (
  'kca_2015_case_27_decision',           -- source (란류 부패 사례)
  'ecmc_2016_case_123_decision',        -- target (신선식품 부패 사례)
  'related',                             -- relation_type (유사 사례)
  NOW()
);

```

구분	필드명	데이터 타입	설명	예시
document	doc_id	VARCHAR(255)	문서 고유 ID	
	doc_type	VARCHAR(50)	타입 구분	law , mediation_case , counsel_case , criteria_*
	title	TEXT	문서 제목	
	source_org	VARCHAR(100)	출처 기관	KCA , ECMC , statute 등
	category_path	TEXT[]	카테고리 경로	{ '농수축산물', '란류' }
	url	TEXT	원본 URL	
	collected_at	TIMESTAMP	수집 일시	
	metadata	JSONB	모든 타입의 정보 저장	- 법령: { "law_number": "...", "enforcement_date": "..."} - 사례: { "case_number": "...", "decision_date": "...", "referenced_laws": [...] } - 기준: { "table_name": "...", "part": "..." }
chunks	created_at	TIMESTAMP		
	updated_at	TIMESTAMP		
	chunk_id	VARCHAR(255)	청크 고유 ID	
	doc_id	VARCHAR(255)	외래키	
	chunk_index	INTEGER	청크 순서	
	chunk_total	INTEGER	해당 문서의 총 청크 수	
	chunk_type	VARCHAR(50)	청크 타입	article , resolution_row , decision , ...
	content	TEXT	청크 내용	
	content_length	INTEGER	청크 내용 길이	
	embedding	vector(1024)	임베딩 차원	
	created_at	TIMESTAMP		

구분	필드명	데이터 타입	설명	예시
	updated_at	TIMESTAMP		
chunk_relations	source_chunk_id	VARCHAR(255)	관계의 출발 청크	
	target_chunk_id	VARCHAR(255)	관계의 도착 청크	
	relation_type	VARCHAR(50)	관계 타입	- next : 다음 청크 (순차) - prev : 이전 청크 (역순) - cited : 인용 관계 (A가 B를 인용) - related : 연관 관계 (유사 주제)
	created_at	TIMESTAMP		

- 데이터 수집 기간: 2025.12.18. - 2025.12.29.
- 전체 수집 데이터 건수:
 - 법령 데이터
 - 문서 20개 / 청크 6300개
 - 피해구제사례데이터
 - 문서 13544개 / 청크 13544개
 - 분쟁조정사례데이터
 - 문서 3173개 / 청크 11755개
 - 분쟁조정기준 데이터
 - 문서 6개 / 청크 892개

2. 데이터 수집 및 활용의 적법성 검토

구분	상업 이용 가능	학습 사용 허용	크롤링 이용약관 준수	개인정보 보호	비고
DATA-001	X	O	O	미포함(마스킹)	
DATA-002	X	O	O	미포함(마스킹)	
DATA-003	X	O	O	미포함(마스킹)	
DATA-004	X	O	O	미포함	
DATA-005	X	O	O	미포함	
DATA-006	X	O	O	미포함	
DATA-007	X	O	O	미포함	
DATA-008	O	O	O	미포함	
DATA-009	O	O	O	미포함	
DATA-010	O	O	O	미포함	
DATA-011	O	O	O	미포함	

구분	상업 이용 가능	학습 사용 허용	크롤링 이용약관 준수	개인정보 보호	비고
DATA-012	O	O	O	미포함	

- 저작권 준수
 - 공공누리(KOGL) 유형 표기"가 있는 자료만 상업/학습/2차가공 가능 여부를 판단 가능
 - 법령
 - OpenAPI 기반 수집으로 저작권 준수
 - 분쟁조정기준
 - 한국소비자원에서 제공하는 "소비자분쟁기준" 자료 사용
- 크롤링 이용약관 준수
 - KCA

```
User-agent: *
Allow: /
Disallow: /base
Disallow: /eniaccms
Disallow: /search
Disallow: /upload
Disallow: /upload2
```

⇒ <https://www.kca.go.kr/odr/cm/in/exmplPgItem.do> 사이트는 /odr로 끝나기 때문에 안전

- ECMC

```
User-agent: *
Disallow: /consult/admin/
Disallow: /onlinead/admin/
```

⇒ admin/ 경로를 제외한 모든 경로는 안전

- 소비자24 ([consumer.go.kr](https://www.consumer.go.kr))

```
user-agent: *
Disallow: /ftc/
Disallow: /gtm/
Disallow: /user/ftc/consumer/goodsinfo/*/selectGoodsInfoList.do
Disallow: /user/ftc/consumer/goodsinfo/*/selectGoodsInfoDetail.do
Disallow: /user/ftc/consumer/dmrecnslt/*/selectDmreCnsltView.do
Disallow: /new/
Disallow: /chatbotManager/
Sitemap: https://www.consumer.go.kr/sitemap.xml
```

⇒

<https://www.consumer.go.kr/user/ftc/consumer/dmgerlifcase/115/selectDmgeRlifCaseList.do>

경로는 디테일한 경로(ftc/consumer/dmgerlifcas전

- 개인정보 보호
 - 법령, 분쟁조정 기준 : 개인정보 미포함
 - 분쟁조정사례, 피해구제 및 상담 사례 : 개인정보 마스킹됨
 - 한국소비자원, 소비자24, 전자거래분쟁조정위원회, 콘텐츠분쟁조정위원회의 경우, 사례집에서 개인정보는 마스킹 처리 (ex. oooooo) 되어있음

3. 수집 자동화

- 수집 항목 및 품질 기준: 수집 데이터 필드와 정상 상태(기준) 작성
- 수집 방식 및 도구:
 - 법령 API
 - BeautifulSoup4
 - 각 조정위원회 사례집 pdf
 - 한국소비자원 분쟁조정기준 pdf
- 전처리 방식 및 도구:
 - 법령
 - XML → JSONL
 - 분쟁조정기준
 - PDF → JSON → JSONL
 - 피해구제 및 상담사례
 - HTML → JSONL
 - 분쟁조정사례
 - PDF → JSON → txt → JSONL
 - 도구
 - OpenAPI
 - Upstage Document Parsing
- 데이터 수집 자동화 코드:
 - 추가 예정 (중간 발표 이후)
 - 법령 데이터
 - 매달 1일 갱신
 - 법령 데이터는 갱신이 빠르다
 - 현재 데이터와 비교하여 추가·변경된 데이터만 적재·청킹

- 분쟁조정기준 데이터
 - 매년 1월 갱신
 - PDF 파싱 → JSONL 방식 자동화 필요
- 피해 구제 및 상담 사례 데이터
 - 매년 1월 갱신
 - 웹페이지 상담 데이터 수집
 - robots.txt, 이용정책 준수
- 분쟁조정사례 데이터
 - 매년 1월 갱신
 - 분쟁조정사례 데이터 수집 (PDF)
 - PDF 파싱 → JSONL 방식 자동화 필요
- 데이터 유효성을 검증하는 방법:
 - JSONL 파일 각 항목 점검
 - 결측치 점검
 - 분할 기준 점검
- 수집 데이터 건수:
 - 법령 데이터
 - 문서 20개 / 청크 6300개
 - 피해구제사례데이터
 - 문서 13544개 / 청크 13544개
 - 분쟁조정사례데이터
 - 문서 3173개 / 청크 11755개
 - 분쟁조정기준 데이터
 - 문서 6개 / 청크 892개
- 자동화 여부 및 주기:
 - 추가 예정 (중간 발표 이후)
 - 분쟁조정사례, 피해구제 및 상담 사례 : 매년 1월 (예정)
 - 법령 : 매달 1일 (예정)
 - 조정 기준 : 매년 1월 (예정)

4. 전처리 프로세스 개요

- 전체 흐름도:

① 수집 → ② 결측치 탐지 → ③ 정규화 → ④ 데이터 청킹 → ⑤ 데이터 임베딩

- 전처리 파이프라인 요약:

단계	목적	수행 작업	사용 도구/라이브러리
수집	데이터 수집	pdf parsing, crawling	Upstage Document parsing, BeautifulSoup4 xml.etree.ElementTree
결측치 탐지	결측치 제거	중복값 제거	
정규화	특수문자 처리	개행문자, 탭문자 등 parsing 결과 전처리	regex
데이터 청킹	RAG 활용	문서 기반 청킹	
데이터 임베딩	유사도 기반 검색	RunPod 활용 문서 임베딩	KURE-v1, text-embedding-3-small

- 도식화

데이터 구조

